scheduler

开始前,我们做一部分记录,由于目前是在win下学习和调试代码,在win下需要注意如下事项:

- windows的git for windows在clone代码的时候,是默认不支持软连接的,如果直接使用git clone下载,会把软连接下载成为包含软连接路径的一个文件,go是无法识别的。git clone的时候加入-c core.symlinks=true这个参数,并且软连接的建立需要管理员的特定权限。
- 下载的路径应该放在\$GOPATH/src/k8s.io下,因为kubernetes的源码中引包路径就是k8s.io/.....
- 关于scheduler的调试,因为scheduler相对是独立的k8s组件,所以可以通过IDE,比如goland在个人PC上debug,访问虚拟机里搭建好的k8s集群,k8s集群disable掉自身的scheduler组件,在个人PC通过master节点ip从集群外访问apiserver,可以直接采用集群内部的scheduler.conf配置文件。由于我是采用kubeadm搭建的单节点集群,从外部通过外网ip访问apiserver时,会出现x509,可参考如下链接处理。另外切记调试的scheduler版本和其他组件版本应该匹配,否则可能会有版本不兼容问题。https://stackoverflow.com/questions/46360361/invalid-x509-certificate-for-kubernetes-master

生成scheduler配置

接下来正式开始源码的学习,第一部分是scheduler,首先我们找到这部分的入口,

kubernetes_src_code > = src > = k8s.io > = kubernetes > = cmd > = kube-scheduler > = scheduler.go

```
func main() {
   rand. Seed(time. Now(). UnixNano())
   command := app. NewSchedulerCommand()
   // TODO: once we switch everything over to Cobra commands, we can go back to calling
   pflag. CommandLine. SetNormalizeFunc (cliflag. WordSepNormalizeFunc)
   logs. InitLogs()
   if err := command. Execute(); err != nil {
       os. Exit (code: 1)
Func NewSchedulerCommand(registryOptions ... Option) *cobra.Command {
   opts, err := options. NewOptions()
       klog. Fatalf (format: "unable to initialize command options: %v", err)
               os. Exit (code: 1)
```

首先关于NewSchedulerCommand()方法,

- NewOptions()主要用于对scheduler进行默认配置的获取,包括默认监听端口、默认 调度器的名称、认证和鉴权配置
- flag相关主要是读取文件配置,对对应flag的默认配置进行重写。

```
fs := cmd.Flags()
namedFlagSets := opts.Flags()
verflag.AddFlags(namedFlagSets.FlagSet( name: "global"))
globalflag.AddGlobalFlags(namedFlagSets.FlagSet( name: "global"), cmd.Name())
for _, f := range namedFlagSets.FlagSets {
    fs.AddFlagSet(f)
}
```

对于cobra,执行根命令kube-scheduler,会对应执行runCommand方法。同时在下方也添加了Usage Help相关的命令行。

```
if err := command. Execute(); err != nil {
   fmt. Fprintf(os. Stderr, format: "%v\n", err)
   os. Exit(code: 1)
}
```

在main方法中,command.Execute(),接下来重点进入到runCommand方法,

- 进行Validate(),对scheduler的相关配置进行校验,包括监听端口有效性、调度器名称、scheduler高可用的配置等
- 另外一个就是Config()方法,该方法基于opt返回scheduler的config,其中applyTo()方法用于将opt相关的配置生效到KubeSchedulerConfiguration这个结构体中,而KubeSchedulerConfiguration又是schedulerappconfig结构体中的一部分,

scheduler实例config配置结构体如下,还包含了请求apiserver的client、处理event的client、高可用相关的配置以及informer相关的封装。

生成scheduler对象

如上就搞定了scheduler运行相关的配置,接下来就会带着上面的配置进入到Scheduler 运行相关的逻辑,执行Run(cc, stopCh)这个方法。

* 首先看下scheduler结构体,

scheduler其实就是一个属性

```
Scheduler watches for new unscheduled pods. It attempts to find // nodes that they fit on and writes bindings back to the api server.

Stype Scheduler struct {

config *factory.Config}
```

我们后面看下这个factory.Config这个结构体

```
type configFactory struct {
   // 与api-server通信的客户端
   client clientset.Interface
   // queue for pods that need scheduling
   // 存着那些需要调度的pod
   podQueue internalqueue.SchedulingQueue
   // a means to list all known scheduled pods.
   // 可以获得所有已经调度的pod
   scheduledPodLister corelisters.PodLister
   // a means to list all known scheduled pods and pods assumed to have been scheduled.
   // 可以获得所有已经调度的pod和那些assumed pod
   podLister algorithm.PodLister
   // a means to list all nodes
   nodeLister corelisters.NodeLister
   // a means to list all PersistentVolumes
   pVLister corelisters.PersistentVolumeLister
   // a means to list all PersistentVolumeClaims
   pVCLister corelisters.PersistentVolumeClaimLister
   // a means to list all services
   serviceLister corelisters.ServiceLister
   // a means to list all controllers
   controllerLister corelisters.ReplicationControllerLister
   // a means to list all replicasets
   replicaSetLister appslisters.ReplicaSetLister
   // a means to list all statefulsets
   statefulSetLister appslisters.StatefulSetLister
   pdbLister policylisters.PodDisruptionBudgetLister
   // a means to list all StorageClasses
   storageClassLister storagelisters.StorageClassLister
   StopEverything <-chan struct{}
   scheduledPodsHasSynced cache.InformerSynced
   schedulerCache schedulerinternalcache.Cache
   // 调度器的名字 默认为default-scheduler
   schedulerName string
   // RequiredDuringScheduling affinity is not symmetric, but there is an implicit PreferredDuri
   // corresponding to every RequiredDuringScheduling affinity rule.
   // HardPodAffinitySymmetricWeight represents the weight of implicit PreferredDuringScheduling
   hardPodAffinitySymmetricWeight int32
   // 加速predicate阶段的equivalence class cache
   equivalencePodCache *equivalence.Cache
   // Enable equivalence class cache
   enableEquivalenceClassCache bool
   // Handles volume binding decisions
   volumeBinder *volumebinder.VolumeBinder
   // Always check all predicates even if the middle of one predicate fails.
   alwaysCheckAllPredicates bool
   // Disable pod preemption or not.
   // 是否禁止抢占
   disablePreemption bool
   // percentageOfNodesToScore specifies percentage of all nodes to score in each scheduling cyc
   percentageOfNodesToScore int32
```

包括如下定义,

各种资源的Lister, Lister是列出各种资源的方法,包括pod、node、PV、PVC、svc、rc、rs、ss、pdb、storage、已经调度的pod和assumed pod(为了考虑性能,在调度环

境不会直接调用apiserver完成bind,而是假设调度的结果可以bind的,此类型pod就是assumed pod) Lister

与apiserver通信的client、需要调度的pod队列、调度器的名称、是否禁止抢占

*接下来进入sccheduler的New()方法,

New方法入参是前面scheduler config的各种参数,返回前面这个结构体。

- schedulerCache := internalcache.New(30time.Second, stopEverything)
 初始化了一个schedulerCache, schedulerCache会不断的更新Pod和Node信息
- 2. c.scheduledPodLister = assignedPodLister{args.PodInformer.Lister()} args.PodInformer.Lister()可以获得所有的pod, 过滤可以得到已经被调度的pod c.scheduledPodLister
- 3. go cc.PodInformer.Informer().Run(stopCh) cc.InformerFactory.Start(stopCh) 开启podinformer
- 4. 等LeaderElection 完成后,默认支持高可用,运行run,执行sched.Run()

执行调度器sched.Run

时间间隔是0s,串行循环执行schedulerOne方法,scheduleOne方法是调度最核心的逻辑,调度一个pod的完整逻辑流程。

1. NextPod()从queue中获取待调度的下一个pod, debug时此时pod为pending状态

```
    ▼ = pod = {*k8s.io/kubernetes/vendor/k8s.io/api/core/v1.Pod | 0xc0009d0380}
    ▶ f TypeMeta = {k8s.io/kubernetes/vendor/k8s.io/apimachinery/pkg/apis/meta/v1.TypeMeta}
    ▶ f ObjectMeta = {k8s.io/kubernetes/vendor/k8s.io/apimachinery/pkg/apis/meta/v1.ObjectMeta}
    ▶ f Spec = {k8s.io/kubernetes/vendor/k8s.io/api/core/v1.PodSpec}
    ▶ f Status = {k8s.io/kubernetes/vendor/k8s.io/api/core/v1.PodStatus}
```

2. scheduleResult, err := sched.schedule(pod) 完成pod的调度,得到调度的节点信息

进入schedule(pod),

```
func (sched *Scheduler) schedule(pod *v1.Pod) (core.ScheduleResult, error) {
    result, err := sched.config.Algorithm.Schedule(pod, sched.config.NodeLister)

if err != nil {
    pod = pod.DeepCopy()
    sched.recordSchedulingFailure(pod, err, v1.PodReasonUnschedulable, err.Error())
    return core.ScheduleResult{}, err
}

return result, err
```

继续进入该方法 result, err := sched.config.Algorithm.Schedule(pod, sched.config.NodeLister)

- * pod进行检测,是否有pv挂载。
- * 通过nodeLister方法获取所有节点
- * 更新node信息快照

进入预选逻辑

进入findNodesThatFit,该方法即是node预选的核心逻辑。

* allNodes := int32(g.cache.NodeTree().NumNodes())

获取所有node的数量

* numNodesToFind := g.numFeasibleNodesToFind(allNodes)

```
if numAllNodes ( minFeasibleNodesToFind (numAllNodes int32) (
if numAllNodes < minFeasibleNodesToFind || g.percentageOfNodesToScore >= 100 {
    return numAllNodes
}

adaptivePercentage := g.percentageOfNodesToScore
if adaptivePercentage <= 0 {
    adaptivePercentage = schedulerapi. DefaultPercentageOfNodesToScore - numAllNodes/125
    if adaptivePercentage < minFeasibleNodesPercentageToFind {
        adaptivePercentage = minFeasibleNodesPercentageToFind
    }
}

numNodes = numAllNodes * adaptivePercentage / 100
if numNodes < minFeasibleNodesToFind {
        return minFeasibleNodesToFind {
        return minFeasibleNodesToFind }
}

return numNodes</pre>
```

设定最多需要进行筛选的节点数量,避免node数太多影响调度效率。这部分的逻辑是

- 1. 如果节点数小于minFeasibleNodesToFind(默认为100),或者设定的 percentageOfNodesToScore(百分比,默认为50)大于100,则返回总节点数
- 2. 如果节点数大于100,则numNodes根据总节点数换算percentageOfNodesToScore 与100的比例得到最终结果
- * 该方法启动16个workers完成int(allNodes)个checkNode任务,该方法实现可以参考用在平时类似场景。

```
ParallelizeUntil(ctx context.Context, workers, pieces int, doWorkPiece DoWorkPieceFunc)
if ctx != nil {
wg. Add (workers)
       defer wg. Done()
               doWorkPiece(piece)
    wg. Wait()
```

首先假定我们需要对100个node进行check,此时我们启动16个workers完成该任务

- 1. 定义一个长度为100的channel,依次写入0-99的整数进该channel
- 2. 如果任务数小于worker数,那么worker数置为与任务数相同
- 3. 循环16个worker,每个worker循环从前面channel中获取编号,然后去处理对应编号的任务
- 4. 最后wg.Wait()等待所有worker任务完成。
- *接下来我们看上面方法实际执行的任务checkNode

```
checkNode := func(i int) {
   nodeName := g. cache. NodeTree(). Next()
   fits, failedPredicates, err := podFitsOnNode(
        pod,
        meta,
        g. nodeInfoSnapshot. NodeInfoMap[nodeName],
        g. predicates,
        g. schedulingQueue,
        g. alwaysCheckAllPredicates,
)
```

- 1. 首先从NodeTree()获取下一个node
- 2. 判断当前node和pod是否满足调度要求,即podFitsOnNode()方法,后面会详细解析该方法
- 3. 如果返回为true,表示当前pod满足调度要求,就将该节点加入filtered列表
- 4. 如果返回为false或报错,就将node加入failedPredicateMap[nodeName]中,并且记录下不满足的err

* 分析podFitsOnNode()

这个方法是根据pod和nodeinfo判断pod是否fit node。 从下面的逻辑中,我们可以看出通过两次for循环执行了两次预选

- 1. 关于两次执行预选的理解,在源码的注释里有详细的解释,在第一次时,可能会有其他 优先级大于等于 当前pod的其他pod已经bind到当前node,但是还未完成调度过程,此时我们需要将这些pods加入到meta和node info后再进行一次预选。
- 2. 如果加入更高优先级pods后进行预选,当前node满足调度条件,那么就需要进行第二次预选计算,就是不加入更高优先级pod情况下,进行计算,判断node是否满足调度。-----这部分的原因是可能会有pod亲和性相关的机制,此时就需要考虑更高有限级pods没有加入时能否满足亲和性条件。

```
// predicates. Ordering()可以得到[]string,包含所有perdicates方法列表

for _, predicateKey := range predicates. Ordering() {
    var (
        fit bool
        reasons []predicates. PredicateFailureReason
        err error
)

// TODO (yastij) : compute average predicate restrictiveness to export it as Prometheus metric

// predicateFuncs是一个map, key是方法名, value是对应的func

// 如果存在对应的方法,那么就进入下面的逻辑
    if predicate, exist := predicateFuncs[predicateKey]; exist {
        // 通过对应的perdicate方法进行node能否调度的判断逻辑
        fit, reasons, err = predicate(pod, metaToUse, nodeInfoToUse)
        if err != nil {
            return false, []predicates. PredicateFailureReason{}, err
```

3. 那么具体的预选方法有哪些呢?

```
var (
predicatesOrdering = []string{CheckNodeConditionPred, CheckNodeUnschedulablePred,
GeneralPred, HostNamePred, PodFitsHostPortsPred,
MatchNodeSelectorPred, PodFitsResourcesPred, NoDiskConflictPred,
PodToleratesNodeTaintsPred, PodToleratesNodeNoExecuteTaintsPred, CheckNodeLabelPresencePred,
CheckServiceAffinityPred, MaxEBSVolumeCountPred, MaxGCEPDVolumeCountPred, MaxCSIVolumeCountPred,
MaxAzureDiskVolumeCountPred, MaxCinderVolumeCountPred, CheckNodeMemoryPressurePred, CheckNodeMemoryPressurePred, CheckNodePIDPressurePred, CheckNodeDiskPressurePred, MatchInterPodAffini
)
```

我们可以看到,默认的预选方法是按照上图的顺序进行的,当然这个是可以通过被配置文件覆盖的

4. 具体的func是在这个文件里,这部分各个方法的逻辑比较简单,基本可以通过看方法 名确定方法的内容。

```
k8s_rsc_code_v1.5 ⟩ ■ src ⟩ ■ k8s.io ⟩ ■ kubernetes ⟩ ■ pkg ⟩ ■ scheduler ⟩ ■ algorithm ⟩ ■ predicates ⟩ ■ predicates.go
```

进入优选逻辑

经过预选逻辑,我们可以得到filterNodes filteredNodes, failedPredicateMap, err := g.findNodesThatFit(pod, nodes)

- * 如果经过预选逻辑只剩一个node, 那么就将该node与pod进行绑定
- * priorityList, err :=
 PrioritizeNodes(pod,g.nodeInfoSnapshot.NodeInfoMap,
 metaPrioritiesInterface, g.prioritizers, filteredNodes, g.extenders)

```
func PrioritizeNodes(
    pod *v1.Pod,
    nodeNameToInfo map[string]*schedulernodeinfo.NodeInfo,
    meta interface{},
    priorityConfigs []priorities.PriorityConfig,
    nodes []*v1.Node,
    extenders []algorithm.SchedulerExtender,
) (schedulerapi.HostPriorityList, error) {
```

该方法入参包括当前需要调度的pod、key为node name, value为node相关信息的map、包含优选算法的各种信息、node的集合、extender(后续单独分析)

出参设计为一个HostPriority的列表,HostPriority由node的host name和对应的score构成,即每个node会得到加权的分数和。

进入该方法,首先看该方法的注释,我们大概能知道源码中优选的基本逻辑:

- 1. k8s定义了很多优选的方法,对应每个方法传入的pod和nodes列表中每一个node都会有0-10分的score
- 2. 每个方法都有自己的权重
- 3. 最终会对每个node计算出一个所有方法加权后的总分数,总分数最高的node即为优 选的结果

```
if len(priorityConfigs) == 0 && len(extenders) == 0 {
   result := make(schedulerapi.HostPriorityList, 0, len(nodes))
   for i := range nodes {
      hostPriority, err := EqualPriorityMap(pod, meta, nodeNameToInfo[nodes[i].Name])
      if err != nil {
            return nil, err
        }
        result = append(result, hostPriority)
   }
   return result, nil
}
```

当优选算法没有设置或extender也没有配置时,此时相当于给每个node安排一个score为 1

```
var (
    mu = sync. Mutex{}
    wg = sync. WaitGroup{}
    errs []error
)
appendError := func(err error) {
    mu. Lock()
    defer mu. Unlock()
    errs = append(errs, err)
}
```

定义并发等待的mutex,一个lock和错误集合 定义了一个err收集的方法,为了保证并发场景下写入errs同步,用了锁机制

```
results := make([]schedulerapi.HostPriorityList, len(priorityConfigs), len(priorityConfigs))
```

定义了一个result,是一个HostPriorityList的列表,len和cap与PriorityConfig数量相同

```
// PriorityConfig is a config used for a priority function.

Type PriorityConfig struct {

Name string

Map PriorityMapFunction

Reduce PriorityReduceFunction

// TODO: Remove it after migrating all functions to

// Map-Reduce pattern.

Function PriorityFunction

Weight int
```

这是PriorityConfig的结构,包含部分旧的算法Function,也包含map-reduce模式的新的方法,Name和Weight分别代表该算法对应的名称和去权重。

```
// DEPRECATED: we can remove this when all priorityConfigs implement the
// Map-Reduce pattern.
for i := range priorityConfigs {
    if priorityConfigs[i].Function != nil {
        wg. Add( deMa: 1)
        go func(index int) {
            defer wg. Done()
            var err error
            results[index], err = priorityConfigs[index].Function(pod, nodeNameToInfo, nodes)
        if err != nil {
            appendError(err)
        }
        }(i)
    } else {
        results[i] = make(schedulerapi.HostPriorityList, len(nodes))
}
```

首先是旧的function的处理逻辑,我们可以看出传入的算法列表中,当旧的function存在时,采用旧的function进行优选计算,此处并发的计算每个旧的function对于node列表的score,每个function对应node列表计算出来一个score列表,存入results[index],index为传入的function序号。

接下来就是map-reduce的逻辑,其实map是映射本质上就是用传入的方法对列表中的每个元素进行f操作,而reduce就是归约,综合列表中所有元素,比如求和等得到最终结果。

```
workqueue.ParallelizeUntil(context.TODO(), workers: 16, len(nodes), func(index int) {
    nodeInfo := nodeNameToInfo[nodes[index]. Name]
    for i := range priorityConfigs {
        if priorityConfigs[i].Function != nil {
            continue
        }

        var err error
        results[i][index], err = priorityConfigs[i].Map(pod, meta, nodeInfo)
        if err != nil {
            appendError(err)
            results[i][index].Host = nodes[index].Name
        }
    }
}
```

如上是map相关的逻辑,此处又延用了预选中的方法,启动16个worker从nodes列表中执行func任务,具体是什么func任务呢? 我们继续看,进入循环首先判断是否有old 的function,如果不为nil,则表明该算法已经用old func处理过了,此时进入map逻辑,map对每个node进行function结果的运算映射,结果存在results[i]中,i表示function序号,index表示node序号。所以此时得到的results对应每个算法每个node的score。

接下来就要对该结果进行reduce,

```
for i := range priorityConfigs[i].Reduce == nil {
    continue
    }
    wg.Add(dela:1)
    so func(index int) {
        defer vg.Done()
        if err := priorityConfigs[index].Reduce(pod, meta, nodeNameToInfo, results[index]); err != nil {
            appendError(err)
        }
        if klog.V(level 10) {
            for _, hostPriority := range results[index] {
                 klog.Infof(format. %v -> %v: %v, Score: (%d) , util.GetPodFullName(pod), hostPriority.Host, priorityConfigs[index].Name, hostPriority.Score)
        }
        }
    }
} (ii)
}
// Wait for all computations to be finished.
wg.Wait()
```

reduce进行归约,得到result中每个算法对应所有节点的score

```
for i := range nodes {
    result = append(result, schedulerapi.HostPriority{Host: nodes[i].Name, Score: 0})
    for j := range priorityConfigs {
        result[i].Score += results[j][i].Score * priorityConfigs[j].Weight
    }
}
```

外层循环遍历node,内层循环遍历算法,按照权重计算出每个node的score。

* 优选中func和map-reduce的逻辑

TODO....

前面的优选计算完成后,我们一层层退出到schedOne的主逻辑

可以看到如果没有调度到合适的node,且此时没有开启抢占机制,那么就会调度失败,该方法return,等待下一次调度。

如果没有调度到合适的node,此时开启了抢占机制,此时就会进入下面的方法。

```
func (sched *Scheduler) preempt(preemptor *v1.Pod. scheduleErr error) (string, error) {
    preemptor, err := sched.config.PodPreemptor.GetUpdatedPod(preemptor)
    if err != nil {
        klog.Errorf(format "Error getting the updated preemptor pod object: %v", err)
        return "", err
    }

    node, victims, nominatedPodsToClear, err := sched.config.Algorithm.Preempt(preemptor, sched.config.NodeLister, sch
    if err != nil {
        klog.Errorf(format "Error preempting victims to make room for %v/%v.", preemptor.Namespace, preemptor.Name)
        return "", err
    }

    var nodeName = ""
    if node != nil {
        nodeName = node.Name
        // Update the scheduling queue with the nominated pod information. Without
        // this, there would be a race condition between the next scheduling cycle
        // and the time the scheduler receives a Pod Update for the nominated pod.
        sched.config.SchedulingQueue.UpdateNominatedPodForNode(preemptor, nodeName)

        // Make a call to update nominated node name of the pod on the API server.
        err = sched.config.PodPreemptor.SetNominatedNodeName(preemptor, nodeName)

    if err != nil {
        klog.Errorf(format "Error in preemption process. Cannot set 'NominatedPod' on pod %v/%v: %v", preemptor.Name sched.config.SchedulingQueue.DeleteNominatedPodIfExists(preemptor)
        return "", err
}
```

1. 首先更新pod信息,获取到该pod最新的状态

preemptor, err := sched.config.PodPreemptor.GetUpdatedPod(preemptor)

2. 进行preempt过程

```
func (g *genericScheduler) Preempt(pod *v1.Pod, nodeLister
algorithm.NodeLister, scheduleErr error)(*v1.Node, []*v1.Pod,
[]*v1.Pod, error)
```

该方法入参是待调度的pod,集群的nodeLister和前面预选优选调度失败的err,出参是抢占获得的node、以及抢占过程从该node上需要驱逐的pod列表和

todo....

3. 更新NominatedPod队列,这个队列表示的是对于每一个node已经分派的pod队列,所以如果抢占成功,会将抢占过程中得到的node的NominatedPod队列中加入该pod

sched.config.SchedulingQueue.UpdateNominatedPodForNode(preemptor, nodeName)

4. 调用apiserver更新该pod的Status.NominatedNodeName,如果该更新过程失败,则从前面的队列中删除该pod

```
if err != nil {
    klog.Errorf(format: "Error in preemption process. Cannot set 'NominatedPod' on pod %v/%v: %v", p
    sched.config.SchedulingQueue.DeleteNominatedPodIfExists(preemptor)
    return "", err
}
```

5. 由于抢占成功,所以需要将该节点上的部分pod进行驱逐。

```
for _, victim := range victims {
    if err := sched.config.PodPreemptor.DeletePod(victim); err != nil {
        klog.Errorf(format: "Error preempting pod %v/%v: %v", victim.Namespace, victim.Name, err)
        return "", err
    }
    sched.config.Recorder.Eventf(victim, v1. EventTypeNormal, reason: "Preempted", messageFmt"by %v/%v of
}
```